Tidyverse og gg2plot

Simon

15/11/2022

- **1** Kort intro:
- 2 Tidyverse
- GG2plot

Section 1

Kort intro:



Kort intro:

Tidyverse

Tidyverse består af flere underliggende pakker, en af disse er dplyr som jeg bruger til ca. 90% af det data manipulation jeg laver. Hvorfor?

- Syntax er meget det samme som SQL
- De fleste funktioner i dplyr er hurtigere end base R funktioenr
- Designet til at arbejde med pipe funktioner som gør koden mere overskueligt.

gg2plot

 Bruges til mere advanceret visualisering sammenlignet med Base-R's plot funktion. Section 2

Tidyverse

tibbles

Tidyverse benytter tibbles som er lavet på følgende 3 måder:

- benyt selve tibble() funktionen
- Benyt as_tibble() på en eksisterende tabel
- Wris du bruger en hver dplyr funktion på en data frame bliver denne til en tibble.

Det objekt der står inden "pipe" bliver sendt ind som det første argument i det der står efter.

Se nedenstående eksempel.

```
library(tidyverse)
x= c(1,2,3,4,5,6,7,8,9,10)
mean(x)
x %>% mean()
```

Simon

Så vi bruger pipes når vi skal lave flere ændringer til vores dataset i en bestemt rækkefølge.

```
day %>%
  got_up() %>%
  had_breakfast() %>%
  programmed_some_r() %>%
  had_lunch() %>%
  programmed_some_r() %>%
  had_dinner() %>%
  went_to_bed()
```

Eksempel på data manipulation med Tidyverse: Yderligere beskrivelse af funktioner kommer

Vi bruger dataset fra cars pakken

```
library(car)
```

```
cars %>%
  select(dist) %>%
  filter(dist > 4 & dist< 20) %>%
  mutate(sum_dist= cumsum(dist))
```

Vigtigt

Når jeg bruger pipe omskrives det første objekt ikke, hvis jeg ønsker dette brug "margrittr" :

```
library(magrittr)
```

```
cars %<>%
  select(dist) %>%
  filter(dist > 4 & dist< 20) %>%
  mutate(sum_dist= cumsum(dist))
head(cars)
```

pipes

Alternativt giv et nyt navn

```
car_new= cars %>%
  select(dist) %>%
  filter(dist > 4 & dist< 20) %>%
  mutate(sum_dist= cumsum(dist))
```

Simon

vigtige dplyr functions

- filter() picks cases based on their values.
- select() picks variables based on their names.
- arrange() changes the ordering of the rows.
- mutate() adds new variables that are functions of existing variables
- summarise() reduces multiple values down to a single summary.

Simon Tidyverse og gg2plot

Lad os tage et lidt større dataset den her gang

head(starwars)

Hvis der er mange rækker brug glimpse() i stedet:

glimpse(starwars)



Filter()

The verb filter() lets you subset a dataframe by rows (observations), meaning the output will filter for only rows which fulfill a certain condition.

```
starwars %>%
filter(skin_color == "gold")
```

Vigtigt Brug "==", "<=", ">=", ">=" eller "<" for at definer betingelse.

Select()

The verb select() lets you subset a dataframe by column (variable), meaning the output will only contain certain columns in the stated order

```
### Her vælger jeg name og mass
starwars %>%
   select(name, mass)
### Her fjerner jeg name og mass
starwars %>%
   select(-c(name, mass))
```

arrange()

The verb arrange() defines the way the rows of your dataframe are ordered

```
#Fra størst til mindst:
starwars %>%
  select(mass) %>%
  arrange(desc(mass))
#Fra mindst til størt:
starwars %>%
  select(mass) %>%
  arrange(mass)
```

Mutate

The verb mutate() lets you manipulate existing variables or create new ones.

Vi kan lave en ny variable:

```
starwars %>%
  select(mass, height) %>%
  mutate(bmi= mass*height) %>%
  head(3)
```

```
## # A tibble: 3 x 3

## mass height bmi

## <dbl> <int> <dbl>
## 1 77 172 13244

## 2 75 167 12525

## 3 32 96 3072
```

Mutate

The verb mutate() lets you manipulate existing variables or create new ones.

Eller ændre en nuværrende variabel

```
starwars %>%
  select(name, mass) %>%
  mutate(mass = ifelse(mass < 50 , "Thin", "Fat")) %>%
  head(3)
```

Summarize

The verb summarize() reduces your dataset to one observation, which is summarized according to a defined function.

Section 3

GG2plot

Intro til gg2plot

Vi kigger i dag på de to vigtigste elementer under gg2plot, som de selv beskriver på følgende måde:

- **Aestetics**: Devine the "surface" of your plot, in terms of what has to be mapped (size, color) on the x and y (and potentially adittional) axes. Aesteticts are defined within the aes() function.
- Geometries: Visual elements you can see in the plot itself, such as bars, lines, and points. They are defined within various geom_XYZ() functions.

Intro til gg2plot

Hver gang vi laver et plot starter vi med at specificere Aestetics:

```
bike %>% ggplot(aes(x = data$x, y = data$y, fill= data$z))
```

Herefter tilføjer vi hvad selve plottet skal indeholde med geometries:

```
bike %>% ggplot(aes(x = data$x, y = data$y, fill= data$z)) +
  geom_point()
```

visualisering af 1 variable

Lad os bruge et nyt dataset, og kigge på duration af cykel-ture:

```
bike <- readRDS(url("https://github.com/SDS-AAU/SDS-master/ray
```

Brug glimpse for at se dataet:

```
glimpse(bike)
```

```
bike %>% head()
```

Histogram

```
bike %>% ggplot(aes(x = duration_sec)) +
  geom_histogram()
```

```
## 'stat_bin()' using 'bins = 30'. Pick better value with 'bin
```

Simon